

گزارش پروژه برچسب گذاری خودکار

عنوان گزارش:

«گزارش مرداد ماه پروژه برچسب گذاری خودکار محتوای متنی»

نگین شمس

شهریور ۱۴۰۴

فهرست

۱	مقدمه	۱
۱	روش پژوهش	۲
۲	استخراج متون کتاب‌ها	۳
۲	الگوریتم LDA	۴
۷	روش TF-IDF	۵
۸	مدل‌سازی موضوعی سلسله‌مراتبی	۶
۱۱	استفاده از مدل زبانی بزرگ برای برچسب‌گذاری	۷
۱۴	جمع‌بندی	۸
۱۴	کارهای آینده	۹

فهرست شکل‌ها

- شکل ۱: خروجی الگوریتم LDA بر روی متن حاوی ایست‌واژه ۴
- شکل ۲: خروجی الگوریتم LDA بر روی متن پردازش شده ۵
- شکل ۳: معیار سردرگمی به‌ازای تعداد موضوعات ۶
- شکل ۴: نمودار Log Likelihood به‌ازای تعداد موضوعات ۷
- شکل ۵: لغات دارای بیشترین TF-IDF ۸
- شکل ۶: استفاده از مدل BERTopic برای تشخیص موضوعی ۹
- شکل ۷: نمودار دندروگرام مربوط به استخراج موضوعات به‌صورت سلسله‌مراتبی ۱۰
- شکل ۸: بخشی از موضوعات شناسایی شده توسط مدل BERTopic ۱۱
- شکل ۹: نمونه‌ای از دسته‌بندی سلسله‌مراتبی کتاب‌ها در کتابخانه قائمیه ۱۲
- شکل ۱۰: تقسیم متن به بخش‌های کوچک ۱۲
- شکل ۱۱: متن پرامپت مورد استفاده ۱۳
- شکل ۱۲: فراوانی برجسته‌های بخش‌های مختلف کتاب ۱۳

۱ مقدمه

در این مرحله از اجرای پروژه، تلاش شده است تا با تکیه بر ترکیبی از روش‌های آماری، الگوریتم‌های یادگیری ماشین و ابزارهای پردازش زبان طبیعی، مجموعه‌ای از متون استخراج‌شده از پایگاه دیجیتال قائمیه مورد تحلیل موضوعی قرار گیرند. برای دستیابی به این هدف، ابتدا با طراحی و پیاده‌سازی یک خزنده، متون مورد نظر جمع‌آوری شده و سپس با بهره‌گیری از تکنیک‌هایی مانند الگوریتم LDA و روش TF-IDF، تحلیل موضوعی آن‌ها انجام شده است. در ادامه‌ی این گزارش، ابتدا پژوهش‌های مرتبط بررسی شده و سپس مراحل جمع‌آوری داده، پیش‌پردازش، پیاده‌سازی الگوریتم‌ها و تحلیل نتایج به تفصیل ارائه خواهد شد.

۲ روش پژوهش

در فاز نخست از اجرای پروژه، به یکی از کلیدی‌ترین مراحل پردازش متون، یعنی شناسایی و استخراج برچسب‌های موضوعی از مجموعه متون، پرداخته شده است. این فرآیند به منظور سازماندهی، دسته‌بندی و درک محتوای متون انجام می‌پذیرد و پایه‌ای برای تحلیل‌های عمیق‌تر و بازیابی هوشمند اطلاعات فراهم می‌کند. پروژه پیش رو را می‌توان از دو دیدگاه و رویکرد متمایز در زمینه مدل‌سازی موضوعی مورد بررسی و اجرا قرار داد. هر یک از این رویکردها دارای مزایا، معایب و کاربردهای خاص خود هستند که انتخاب آن‌ها به اهداف پروژه، ماهیت داده‌ها و میزان دقت مورد نیاز بستگی دارد. دو رویکرد مورد نظر، به شرح زیر می‌باشد:

- در رویکرد نخست، می‌توان مجموعه‌ای از موضوعات را به کمک ترکیبی از روش‌های خودکار، نیمه‌خودکار و دستی به دست آورد. برای مثال، می‌توان با استفاده از الگوریتم LDA، متون را از لحاظ موضوعی به گروه‌های مختلفی تقسیم نمود که هر گروه با کلمات پرتکرار مرتبط با آن موضوع نشان داده می‌شود. سپس با استفاده از کلمات پرتکرار هر یک از دسته‌بندی‌های موضوعی، می‌توان برچسب مشخصی را به آن‌ها اختصاص داد. برای این کار می‌توان از مدل‌های هوش مصنوعی و یا نیروی انسانی استفاده کرد. همچنین این امکان نیز وجود دارد که بخشی از موضوعات رایج که توسط روش مورد نظر شناسایی نشده‌اند، به صورت کلیدواژه‌های دستی به مجموعه‌ی موضوعات اضافه شوند. نکته‌ای که درباره این روش وجود دارد، شناسایی برچسب‌ها به صورت تک‌سطحی می‌باشد. این روش نمی‌تواند موضوعات را در یک سلسله‌بندی مشخص تقسیم کند.

- در رویکرد دوم، می‌توان از ابتدا روشی برای مدل‌سازی موضوعی سلسله‌مراتبی استفاده نمود. در این روش‌ها مانند $hLDA^1$ ، $nHDP^2$ ، برچسب‌ها به صورت چندسطحی و سلسله‌مراتبی استخراج می‌شوند. این نوع روش‌ها رویکردی کاملاً خودکار برای استخراج یک نقشه موضوعی غنی و دارای عمق از یک مجموعه متنی ارائه می‌دهند. البته باید در نظر داشت که این رویکرد بدون نظارت، ممکن است دقت پایین‌تری نسبت به روش نخست داشته

¹ Hierarchical LDA

² Nested hierarchical Dirichlet process

باشد. این رویکرد برخلاف روش اول که موضوعات را به صورت تخت و مستقل از هم در نظر می‌گیرد، سعی می‌کند ساختار طبیعی و سلسله‌مراتبی بین موضوعات را کشف و مدل کند.

۳ استخراج متون کتاب‌ها

به‌منظور دستیابی به متون کتاب‌های موجود در پایگاه قائمیه برای ایجاد مجموعه داده آموزشی مورد نیاز در فازهای بعدی، طراحی و پیاده‌سازی یک فرآیند خودکار جمع‌آوری داده ضروری بود. برای دستیابی به این هدف، از یک خزنده^۱ اختصاصی استفاده شده است. این خزنده به گونه‌ای طراحی شده است که بتواند به صورت سیستماتیک و ساختاریافته، به حجم عظیمی از متون موجود در این پایگاه دسترسی پیدا کند و آن‌ها را برای پردازش‌های بعدی آماده سازد.

سازوکار عمل خزنده به این شرح است که ابتدا فهرست اصلی موضوعات و دسته‌بندی‌های کتاب‌خانه دیجیتال قائمیه را پیمایش کرده و سپس به صورت مرحله‌ای و با دنبال کردن پیوندهای مربوط به هر کتاب، به صفحه اختصاصی هر یک از کتاب‌ها مراجعه می‌نماید. پس از ورود به صفحه هر کتاب، خزنده مورد نظر متن کامل کتاب را که در قالب فایل‌های HTML (با پسوند .htm) ارائه شده است، دانلود می‌کند. یکی از نکات حائز اهمیت در این فرآیند، حفظ ساختار سازمانی داده‌ها است. به همین منظور، برای هر کتاب، یک پوشه اختصاصی در نظر گرفته می‌شود. این پوشه در بدنه یک ساختار دایرکتوری بزرگتر ایجاد می‌شود که دقیقاً مطابق با سلسله‌مراتب موضوعی و دسته‌بندی‌های اصلی پایگاه قائمیه (مانند فقه، اخلاق، تاریخ، تفسیر و...) است. بنابراین، هر کتاب نه تنها دانلود می‌شود، بلکه بلافاصله در پوشه‌ای که مربوط به دسته‌بندی محتوایی و موضوعی آن کتاب است، ذخیره می‌گردد. این رویکرد در مرحله بعد و برای آموزش مدل‌های موضوعی، یک مزیت بزرگ محسوب می‌شود؛ چرا که برچسب‌های موضوعی اولیه (در صورت استفاده از دسته‌بندی پیش‌فرض) به صورت ضمنی در ساختار پوشه‌ها وجود دارند و می‌توانند به عنوان داده اولیه برای آموزش یا ارزیابی مورد استفاده قرار گیرند.

۴ الگوریتم LDA

در این گام، به‌منظور تست الگوریتم‌های مدل‌سازی موضوعی، بخش کوچکی از متون استخراج‌شده از وب‌سایت قائمیه، به‌طور تصادفی انتخاب شده است انتخاب شده است و سپس الگوریتم LDA^۲، بر روی آن اعمال گردیده است. در این مرحله، به‌منظور آزمایش اولیه و سنجش کارایی الگوریتم‌های مدل‌سازی موضوعی بر روی داده‌های متنی جمع‌آوری‌شده، یک بررسی مقدماتی و محدود طراحی و اجرا گردید. هدف از این فاز، آشنایی عملی با ماهیت داده‌ها، شناسایی چالش‌های احتمالی و به دست آوردن درک اولیه از قابلیت اجرای الگوریتم بر روی این مجموعه داده خاص پیش از انجام محاسبات سنگین روی حجم کامل داده بود.

¹ Crawler

² Latent Dirichlet Allocation

سپس الگوریتم LDA یا تخصیص نهفته دیریکله که به عنوان یکی از پایه‌ای‌ترین، رایج‌ترین و تأثیرگذارترین روش‌های مدل‌سازی موضوعی بدون نظارت در پردازش زبان طبیعی محسوب می‌شود، بر روی این نمونه اعمال گردید. اصول کار این الگوریتم بر پایه‌ای مفروضات آماری ساده اما قدرتمندی استوار است. از موضوعات کشف شده: برای هر موضوع، ۱۰ کلمه‌ای که دارای بالاترین احتمال تعلق به آن موضوع بودند، استخراج شد. این کلمات به عنوان نماینده موضوع و پایه‌ای برای تفسیر و نامگذاری آن عمل می‌کنند. هر موضوع خود به عنوان یک توزیع احتمال بر روی کلیه کلمات موجود در واژگان تعریف می‌گردد. به عبارت دیگر، هر موضوع با مجموعه‌ای از کلمات که با احتمالات خاصی در آن موضوع ظاهر می‌شوند، شناخته می‌شود. هدف LDA این است که این ساختار نهفته را کشف کند؛ یعنی برای هر سند، نسبت موضوعات تشکیل‌دهنده آن را مشخص نماید و برای هر موضوع، کلمات کلیدی و نماینده‌ی آن را استخراج کند.

پیش از اجرای الگوریتم LDA، لازم است متن مورد نظر پیش‌پردازش شود. یکی از گام‌های مهم در جهت پیش‌پردازش متن، حذف ایست‌واژه‌ها می‌باشد. جدول ۱ نشان‌دهنده پرتکرارترین لغات متن مورد بررسی، پیش از انجام هیچ‌گونه پیش‌پردازی می‌باشد.

جدول ۱: پرتکرارترین لغات متون پیش از حذف ایست‌واژه‌ها

تکرار	کلمه
۵۱۶۰	و
۲۶۴۷	در
۲۱۲۲	می
۲۰۹۱	به
۱۹۵۳	از
۱۷۸۷	که
۱۷۶۹	را

همان‌طور که در جدول بالا مشاهده می‌شود، پرتکرارترین لغات، کلماتی هستند که به‌وفور در متن تکرار شده‌اند و بار معنایی متمایزکننده‌ای ندارند. این کلمات ایست‌واژه^۱ نام دارند. در صورتی که این کلمات از متن حذف نشوند، بر روی خروجی الگوریتم LDA تأثیر منفی خواهد داشت. همان‌طور که در شکل ۱ نیز قابل مشاهده است، در صورت عدم حذف این واژه‌ها، برخی از دسته‌بندی‌ها این نوع کلمات خواهد بود و بنابراین دسته‌بندی موضوعی صحیحی نخواهد بود.

^۱ Stop Words

```

Topic 0:
['خدا', 'علیه', 'است', 'می', 'آن', 'به', 'از', 'در', 'را', 'که']
Topic 1:
['ام', 'یه', 'الس', 'اء', 'ار', 'ول', 'اب', 'ان', 'ال', 'ال']
Topic 2:
['supply', 'that', 'is', 'بن', 'in', 'to', 'and', 'of', 'the', 'فی']
Topic 3:
['تور', 'صنعتی', 'می', 'الگوی', 'های', 'را', 'از', 'به', 'در', 'تولید']
Topic 4:
['هم', 'یک', 'از', 'به', 'این', 'را', 'است', 'در', 'که', 'می']
Topic 5:
['الأَنْوار', 'امام', 'ال', 'لا', 'هر', 'از', 'علیه', 'السلام', 'است', 'ال']
Topic 6:
['شود', 'این', 'با', 'می', 'که', 'است', 'های', 'به', 'از', 'در']
Topic 7:
['نوع', 'مطلعه', 'خداوند', 'بزار', 'های', 'در', 'فقهی', 'از', 'اشیاء']
Topic 8:
['در', 'اقتصاد', 'به', 'که', 'برای', 'می', 'cxs', 'افزایش', '1981', 'قیمت']
Topic 9:
['السلام', 'خانه', 'از', 'است', 'با', 'علیه', 'به', 'که', 'می', 'در']

```

شکل ۱: خروجی الگوریتم LDA بر روی متن حاوی ایست‌واژه

به‌منظور حذف ایست‌واژه‌ها از متن، دو فایل مجزا حاوی ایست‌واژه‌های فارسی^۱ و عربی^۲ استفاده شده است. استفاده از فایل ایست‌واژه‌های عربی به این دلیل است که با توجه به ماهیت متون مذهبی، بخش زیادی از کتاب‌ها حاوی عبارات عربی است و در صورت عدم حذف ایست‌واژه‌های عربی، این واژه‌ها نیز در دسته‌بندی موضوعی ارائه‌شده توسط الگوریتم LDA راه پیدا خواهد کرد.

جدول ۲ نشان‌دهنده پرتکرارترین لغات متن مورد بررسی پس از حذف ایست‌واژه‌ها می‌باشد. یکی دیگر از اقداماتی که در جهت پردازش متن استفاده شده است، نرمال‌سازی متن بوده است که با استفاده از کتابخانه پارسی‌ور^۳ صورت پذیرفته است. شکل ۲ نشان‌گر خروجی الگوریتم LDA بر روی متن پیش‌پردازش شده است.

جدول ۲: پرتکرارترین لغات متون پس از حذف ایست‌واژه‌ها

تکرار	کلمه
۱۳۷۸	محمد
۱۱۹۶	تولید

^۱ <https://github.com/kharazi/persian-stopwords>

^۲ <https://github.com/mohataher/arabic-stop-words>

^۳ <https://github.com/ICTRC/Parsivar>

عبد	۵۳۹
اقتصاد	۵۱۷
امام	۲۸۶
علی	۲۴۸
رسول	۲۴۵

```

Topic 0:
[ 'اقتصادی', 'پول', 'تغییر', 'کاهش', 'بازار', 'تقاضا', 'تورم', 'عرضه', 'افزایش', 'قیمت' ]
Topic 1:
[ 'آرد', 'شماره', 'پیوست', 'حضرت', 'سته', 'مسئله', 'روایت', 'خاته', 'تجارت', 'روایت' ]
Topic 2:
[ 'توزیع', 'هدایت', 'بازار', 'المکاسب', 'مشاغل', 'استاندارد', 'فقه', 'صنعتی', 'الگوی', 'تولید' ]
Topic 3:
[ 'اختلال', 'سرفصل', 'بایع', 'بحث', 'مشتري', 'تقاضا', 'تبادل', 'کثور', 'تور', 'تحلیل' ]
Topic 4:
[ 'حیسی', 'عثمان', 'أبي', 'یونس', 'ابن', 'جعفر', 'قلب', 'عبد', 'الله', 'محمد' ]
Topic 5:
[ 'اد', 'ون', 'یه', 'اء', 'ول', 'لس', 'ار', 'اب', 'ال', 'ال' ]
Topic 6:
[ 'مدیریت', 'کلمه', 'اصطلاح', 'عرضه', 'توصیف', 'کار', 'شارع', 'مسئله', 'تولید', 'بحث' ]
Topic 7:
[ 'جدول', 'روایت', 'کنز', 'فقہی', 'دارای', 'مطالعه', 'شیء', 'بودجه', 'خداوند', 'اشیاء' ]
Topic 8:
[ 'الکافی', 'بحار', 'الأنوار', 'خدا', 'تجارت', 'الوافي', 'وسائل', 'فرمود', 'الشیعة', 'السلام' ]
Topic 9:
[ 'توسعه', 'خرد', 'پول', 'سرمایه', 'ملی', 'رشد', 'کلان', 'دولت', 'اقتصادی', 'اقتصاد' ]


```

شکل ۲: خروجی الگوریتم LDA بر روی متن پردازش شده

نکته دیگری که در مورد الگوریتم LDA وجود دارد، این است که تعداد موضوعات باید تحت عنوان پارامتر k به الگوریتم LDA داده شود، بنابراین انتخاب مقدار بهینه K از اهمیت بالایی برخوردار است. برای حل این مسئله، معیارهای ارزیابی مختلفی توسعه داده شده‌اند. یکی از پرکاربردترین این معیارها، شاخص سردرگمی^۱ است. این معیار که بر مبنای احتمال نگهداری داده‌ها محاسبه می‌شود، توانایی مدل در پیش‌بینی داده‌های مشاهده‌نشده را اندازه می‌گیرد. به طور کلی، مقدار پایین‌تر سردرگمی نشان‌دهنده عملکرد بهتر مدل است. از این معیار عموماً برای مقایسه بین مدل‌های مختلف یا مقادیر مختلف k بر روی یک مجموعه داده ثابت استفاده می‌شود. شکل ۳ نشان‌دهنده نمودار شاخص سردرگمی به‌ازای تعداد


¹ Perplexity

موضوعات انتخابی است. با توجه به شکل، نمودار در نقطه $k=6$ دچار شکست شده است و پس از آن یک سیر نزولی را طی می‌کند، بنابراین عدد شش می‌تواند یک مقدار مناسب برای پارامتر k باشد.



شکل ۳: معیار سردرگمی به‌ازای تعداد موضوعات

معیار دیگری که می‌توان برای شناسایی مقدار بهینه k مورد استفاده قرار داد، معیار $\log \text{likelihood}$ است که نمودار آن در شکل ۴ قابل مشاهده است. بر اساس نمودارهای شکل ۳ و شکل ۴، مقدار مناسب برای پارامتر k یعنی تعداد موضوعات می‌تواند عددی در بازه شش تا هشت باشد. با این وجود چنین به‌نظر می‌رسد که این تعداد از موضوعات برای دسته‌بندی موضوعی حجم عظیم داده‌های متنی موجود در پایگاه اینترنتی قائمیه کافی نباشد و لازم است از روش‌های ترکیبی و یا طراحی و تخصیص برچسب به‌صورت دستی نیز استفاده شود.



شکل ۴: نمودار Log Likelihood به‌ازای تعداد موضوعات

۵ روش TF-IDF


محاسبه TF-IDF یکی از روش‌های پایه‌ای و بسیار پرکاربرد در نمایش متن‌ها به صورت عددی است. اگرچه معمولاً برای بازیابی اطلاعات و نمایش ویژگی‌ها استفاده می‌شود، ولی می‌توان از آن به شکل ساده‌ای برای مدل‌سازی موضوعی نیز بهره برد. این معیار دارای دو بخش مختلف است:

- TF (Term Frequency): فراوانی یک کلمه در یک سند مشخص
- IDF (Inverse Document Frequency): معیاری برای سنجش اهمیت یک کلمه در کل مجموعه اسناد

در نهایت، با ترکیب این دو بخش، واژه‌هایی که در یک سند خاص زیاد تکرار شده‌اند ولی در سایر اسناد کمتر دیده می‌شوند، امتیاز بالاتری می‌گیرند. این ویژگی باعث می‌شود TF-IDF ابزار مناسبی برای تشخیص واژه‌های کلیدی در هر سند باشد. سادگی و سرعت بالا از مزایای این روش محسوب می‌شود، با این وجود، این روش نیز معنا و ترتیب کلمات را در نظر نمی‌گیرد و بر اساس مدل کیسه کلمات^۱ عمل می‌کند. همچنین با توجه به نتایج حاصل از این بخش و بخش قبلی،

^۱ Bag of Words

چنین به نظر می‌رسد که بخش زیادی از متون مورد بررسی در این فاز، علاوه بر مضامین مذهبی و دینی، دارای مفاهیم و موضوعات اقتصادی نیز می‌باشد.



شکل ۵: لغات دارای بیشترین TF-IDF

۶ مدل سازی موضوعی سلسله مراتبی

در این بخش تلاش شده است تا برخلاف مراحل قبلی که برچسب‌های حاصل تک سطحی بودند، از روشی برای تهیه برچسب‌های موضوعی چند سطحی استفاده شود. خروجی این روش، یک ساختار درختی از موضوعات است. عمومی‌ترین موضوعات که معمولاً بسامد رخداد بیشتری دارند، در ریشه قرار می‌گیرند. موضوعات نسبتاً عمومی در شاخه‌های میانی قرار دارند. خاص‌ترین و جزئی‌ترین موضوعات مثلاً شرایط صحت نماز در پایین‌ترین سطح یعنی برگ‌ها قرار می‌گیرند. هر سند می‌تواند به چندین موضوع در سطوح مختلف این درخت تعلق داشته باشد. به همین منظور، از مدل BERTopic برای این کار استفاده شده است. BERTopic یک الگوریتم پیشرفته و نوین برای مدل سازی موضوعی است که از ترکیب

تکنیک‌های تعبیه متون^۱ و الگوریتم‌های خوشه‌بندی برای استخراج موضوعات بهره می‌گیرد. برخلاف روش‌های سنتی مانند LDA، این مدل از قابلیت‌های مبتنی بر ترنسفورمر^۲ مانند مدل‌های BERT برای درک عمیق‌تر معنایی متون استفاده می‌کند. یکی از ویژگی‌های برجسته BERTopic، توانایی آن در ایجاد ساختار سلسله‌مراتبی بین موضوعات است که به کاربران اجازه می‌دهد روابط بین موضوعات عمومی و خاص را به صورت یک درخت موضوعی تجسم و تحلیل کنند. تعبیه انتخاب‌شده برای این مدل که یکی از ورودی‌های مدل BERTopic است، یک تعبیه چندزبانی است که زبان فارسی را نیز به‌خوبی پشتیبانی می‌کند.


```
5 embedding_model = SentenceTransformer('paraphrase-multilingual-MiniLM-L12-v2')
6
7
8 # Create embeddings for your documents
9 embeddings = embedding_model.encode(processed_docs, show_progress_bar=True)
10
11
12 # Step A: Create the base topic model
13 topic_model = BERTopic(
14     language='multilingual', # Important for non-English stopwords
15     embedding_model=embedding_model, # Use our Persian model
16     calculate_probabilities=True,
17     verbose=True
18 )
```

شکل ۶: استفاده از مدل BERTopic برای تشخیص موضوعی


¹ Text Embedding

² Transformer-based

با توجه به نتایج حاصل از این بخش، دسته‌بندی سلسله‌مراتبی به‌دست‌آمده از کیفیت کافی برخوردار نبوده و بنابراین از این روش نمی‌توان به‌تنهایی برای دسته‌بندی موضوعی کتب استفاده نمود. شکل ۷ نشان‌دهنده نمودار دندروگرام طبقه‌بندی موضوعی متون مورد بررسی است.



شکل ۷: نمودار دندروگرام مربوط به استخراج موضوعات به‌صورت سلسله‌مراتبی




شکل ۸: بخشی از موضوعات شناسایی شده توسط مدل BERTopic

۷ استفاده از مدل زبانی بزرگ برای برچسب‌گذاری

در گام بعد برای برچسب‌زنی از یک مدل زبانی بزرگ^۱ استفاده شده است. مدل زبانی مورد استفاده در این مرحله، مدل aya-expense است که نتایج خوبی بر روی متون زبان فارسی نشان داده است. به‌منظور استفاده از این مدل برای برچسب‌گذاری متن، در ابتدا لازم است مجموعه‌ای از برچسب‌ها در متن پرامپت به مدل داده شود. به همین منظور در این مرحله با هدف آزمایش و بررسی خروجی مدل زبانی برای برچسب‌گذاری از دسته‌بندی پیش‌فرض موجود در کتابخانه دیجیتالی قائمیه استفاده شده است. دسته‌بندی مورد نظر یک دسته‌بندی سلسله‌مراتبی است، با این تفاوت که برچسب کتاب‌ها علاوه بر برچسب‌های سطح برگ در سلسله‌مراتب، ممکن است از برچسب‌های والد نیز انتخاب شود. برچسب‌های سلسله‌مراتبی موجود در حال حاضر دارای حداقل یک و حداکثر هفت سطح می‌باشند. در مجموع حدود ۶۱۴ برچسب در سطح غیربرگ و ۸۵۲ برچسب در سطح برگ (گره‌های بدون فرزند در درخت سلسله‌مراتب) وجود دارد. شکل ۹ نمونه‌ای از یک دسته‌بندی سلسله‌مراتبی کتب است.

¹ Large Language Model



شکل ۹: نمونه‌ای از دسته‌بندی سلسله‌مراتبی کتاب‌ها در کتابخانه قائمیه

برای تهیه فهرست برچسب‌های مورد نیاز برای مدل زبانی، برچسب‌های سطح برگ جداسازی شده و به‌عنوان ورودی به مدل زبانی داده شده است. در صورتی که تنها ملزم به انتخاب برچسب‌های پایین‌ترین سطح در سلسله‌مراتب باشیم، لازم است اصلاحاتی بر روی ساختار سلسله‌مراتبی موجود صورت بگیرد. برای مثال، ساختار سلسله‌مراتبی زیر دارای هفت سطح است که تنها یک کتاب با برچسب سطح برگ آن وجود دارد:

معصومین (ع) - چهارده معصوم (ع) - امام زمان (عج) - مهدویت امام زمان - ظهور - علائم ظهور - علائم حتمی - دجال در چنین مواردی که تعداد بسیار محدودی کتاب در سطح برگ وجود دارد، بهتر است از جزئی‌تر کردن موضوع برچسب‌ها خودداری نمود و برچسب برگ را برابر با برچسب سطح بالاتر مانند علائم ظهور در نظر گرفت. به همین منظور برچسب‌های سطح برگی که کمتر از ۱۰ کتاب را به خود اختصاص داده بودند، حذف گردیده و کتاب‌های دارای چنین برچسب‌هایی با گره والد خود در سلسله‌مراتب ادغام گردیده‌اند. پس از اجرای این گام، تعداد برچسب‌های سطح برگ به ۳۳۵ برچسب کاهش یافته است.

در گام بعد، با استفاده از چارچوب langchain، متن کتاب به بخش‌های مختلف تقسیم شده است که اصطلاحاً به آن chunk گفته می‌شود. اندازه‌ی هر chunk و میزان هم‌پوشانی بخش‌های مختلف از اهمیت بالایی برخوردار است که در این مرحله برابر با ۱۰۰۰ حرف در نظر گرفته شده است.

```

from langchain.text_splitter import RecursiveCharacterTextSplitter

# Start with a medium-sized chunk, but prioritize paragraph boundaries.
text_splitter = RecursiveCharacterTextSplitter(
    chunk_size=1000, # Target size in characters/tokens
    chunk_overlap=100, # CRITICAL: Overlap between chunks to avoid losing context
    separators=["\n\n", "\n", " ", ""] # Splitting hierarchy
)

chunks = text_splitter.split_text(clean_text)
  
```

شکل ۱۰: تقسیم متن به بخش‌های کوچک

در مرحله بعد، هر یک از chunk های کتاب به همراه فهرست برچسب های سطح برگ به مدل زبانی داده شده است. متن پرامپت مورد استفاده در شکل ۱۱ نمایش داده شده است.

```
tagging_prompt = ChatPromptTemplate.from_template(
    """
    شما یک متخصص کتابدار هستید که متون فارسی را بر اساس یک سیستم طبقه بندی دقیق برچسبگذاری می کنید.

    **فهرست برچسب های موجود (فقط از این لیست انتخاب کنید):**
    {tag_list}


    **دستورالعمل ها:**
    - فقط برچسب هایی را انتخاب کنید که مستقیماً و به طور معناداری در متن مورد بحث قرار گرفته اند.
    - متن را به دقت تحلیل کنید و برچسب های مرتبط را انتخاب نمایید.
    - اگر موضوعی به طور واضح در متن وجود دارد ولی عبارت دقیق آن در لیست نیست، نزدیکترین برچسب را انتخاب کنید.
    - که شامل لیستی از برچسب های انتخاب شده است "tags" معتبر برگردانید با کلید JSON پاسخ را فقط به صورت
    - برچسب ها تنها باید از فهرست برچسب های موجود انتخاب شوند.
    - ترتیب برچسب ها در خروجی اهمیت دارد. برچسب های مرتبط تر ابتدای فهرست خروجی قرار بگیرند.

    **متن برای تحلیل:**
    {text_chunk}

    **خروجی (فقط JSON):**
    """
)
```

شکل ۱۱: متن پرامپت مورد استفاده

با توجه به طولانی بودن متن برخی کتاب ها و به منظور صرفه جویی در زمان، تنها ده درصد از chunk های کتاب انتخاب گردیده و توسط مدل LLM برچسب گذاری شده است. در پایان، برای تصمیم گیری در مورد برچسب های نهایی کتاب، از روش رأی گیری اکثریت استفاده شده است. شکل ۱۲ نشان دهنده فراوانی برچسب های مربوط به بخش های مختلف کتاب است.



شکل ۱۲: فراوانی برچسب های بخش های مختلف کتاب

۸ جمع‌بندی

این فاز پروژه با هدف طراحی و پیاده‌سازی یک سامانه برچسب‌گذاری خودکار برای متون مذهبی فارسی موجود در پایگاه قائمیه آغاز شد. در طول این مسیر، مراحل مختلفی از جمله جمع‌آوری داده‌ها با طراحی یک خزنده اختصاصی، پیش‌پردازش متون، و اعمال الگوریتم‌های مختلف مدل‌سازی موضوعی شامل روش‌های کلاسیک مانند LDA و TF-IDF و روش‌های جدیدتر و مبتنی بر یادگیری عمیق مانند BERTopic مورد بررسی قرار گرفت. یافته‌های این فاز به وضوح نشان داد که هیچ‌یک از الگوریتم‌ها به تنهایی نمی‌توانند پاسخگوی کامل نیازهای یک سیستم برچسب‌گذاری دقیق و معنادار باشند. هر روش نقاط قوت و ضعف خاص خود را دارد. روش‌های LDA و TF-IDF برای استخراج کلمات کلیدی حاوی نتایج خوبی است اما یک روش مدل‌سازی موضوعی کامل نیست. BERTopic نیز علی‌رغم توانایی در کشف ساختار سلسله‌مراتبی، نیاز به تنظیم دقیق دارد و ممکن است در تفسیرپذیری با چالش مواجه شود. چالش‌های خاص متون مذهبی، از جمله آمیختگی زبان فارسی و عربی، وجود اصطلاحات تخصصی، و حساسیت بالای معنایی، بر پیچیدگی مسئله افزوده و نیاز به راه‌حل‌های ترکیبی را آشکار کرده است.

۹ کارهای آینده

در ادامه این پژوهش، مسیرهای متعددی برای تکمیل و ارتقای سیستم پیشنهاد می‌شود. نخست، تلفیق رویکردهای مختلف مدل‌سازی موضوعی شامل ترکیب نقاط قوت مدل‌های کلاسیک و پیشرفته می‌تواند به بهبود دقت و پوشش موضوعی منجر شود. دوم، بهبود فرآیند پیش‌پردازش متون تخصصی از طریق توسعه کتابخانه ایست‌واژه‌های حوزه دینی، پیاده‌سازی الگوریتم‌های جداسازی خودکار متون عربی و فارسی، و بهینه‌سازی روش‌های ریشه‌یابی ویژه متون کهن ضروری است. سوم، به کارگیری مدل‌های زبانی بزرگ برای نامگذاری هوشمند موضوعات و افزایش تفسیرپذیری نتایج از اولویت‌های کلیدی خواهد بود. چهارم، ایجاد مجموعه داده استاندارد با برچسب‌گذاری متخصصان و طراحی معیارهای ارزیابی کیفی می‌تواند اعتبارسنجی سیستم را ارتقا دهد. پنجم، ارائه یک رابط برای برچسب‌گذاری خودکار متون و در نهایت، روش‌های کاهش ابعاد پیشرفته از دیگر مسیرهای توسعه این پژوهش خواهند بود.